Συστήματα ανάκτησης πληροφοριών

2η Φάση Προγραμματιστικής Εργασίας

Βιβλιοθήκη LISA

Ον/μο: ΒΙΤΑΛΗΣ ΙΩΑΝΝΗΣ
ΑΜ: 3150011

Τελική Δομή:

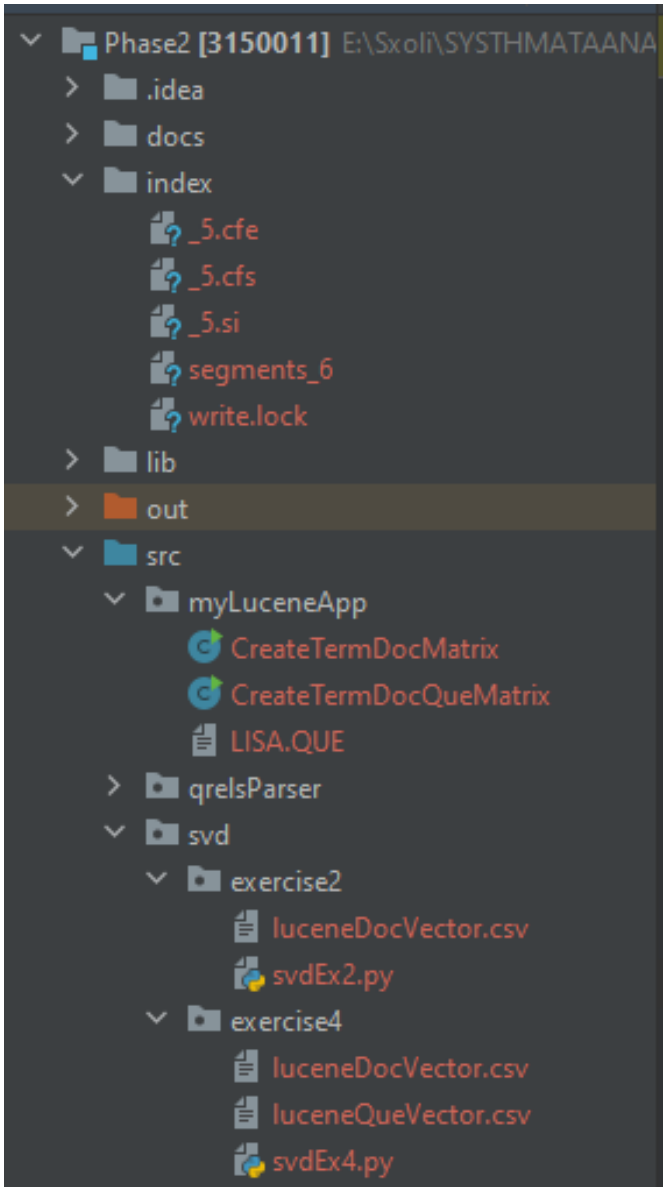

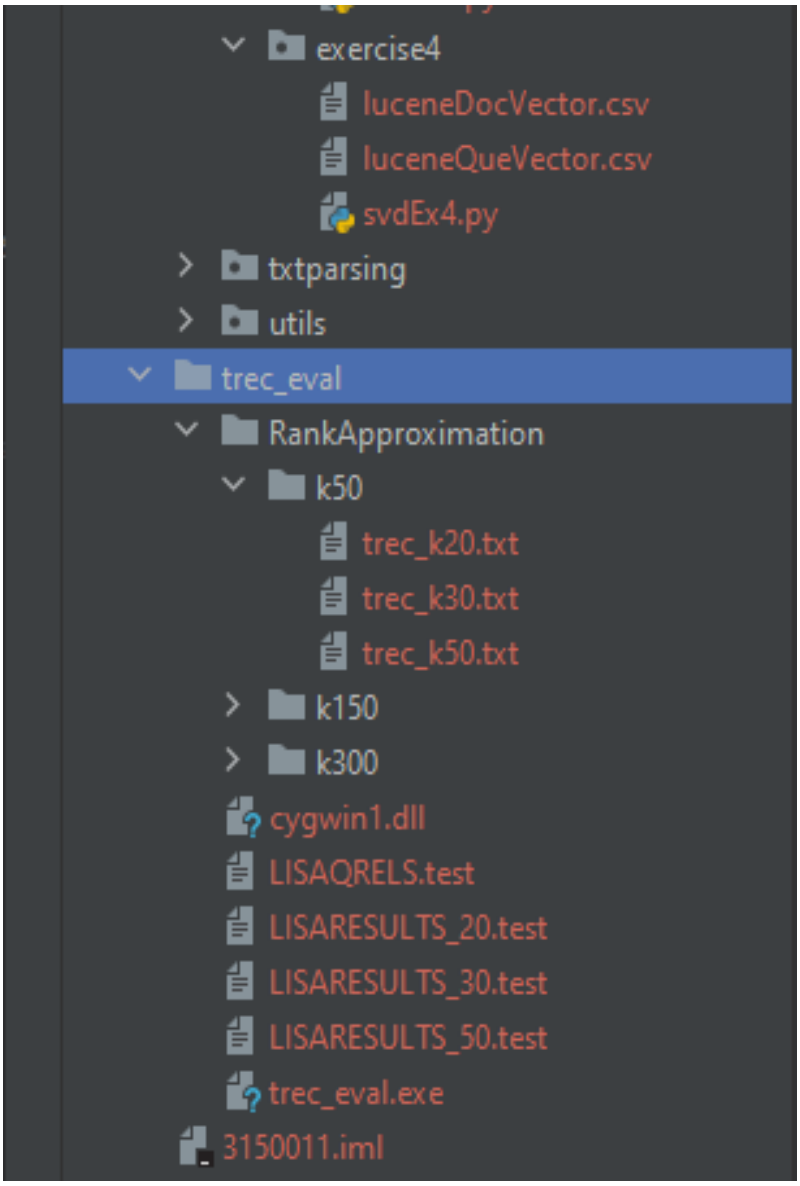

Σημαντικο!
Ξεκίνησα ακολουθώντας την ροή της εκφώνησης κατασκευάζοντας τον termXdocument πίνακα για τον πρώτο ερώτημα με **13579** terms, χρησιμοποιώντας την TXTparsing όπως ακριβώς την είχα κατασκευάσει για την 1η Φάση της προγραμματιστικής εργασίας. Ο τελικός termXdocument πίνακας είχε διαστάσεις **13579x6004** με τον οποίο έκανα επιτυχώς SVD ανάλυση για το 2ο βήμα χρησιμοποιώντας python.
Προχωρώντας στο βήμα 3, οπου απαιτούνταν η ενσώματωση των terms των queries στα terms των documents δημιουργώντας ένα ενιαίο index κατέληξα με **13774** terms και συνολικά **6039** documents(docs+queries) από τον οποίο θα δημιουργούσα τα δύο αρχεία που απαιτούνται για τον υπολογισμό της συνημιτονοειδής ομοιότητας των διανυσμάτων των ερωτημάτων με τα διανύσματα των κειμένων.

Παρόλα αυτά έτρεχε η “testSparseFreqDoubleArrayConversion(IndexReader reader)” για περίπου 2 λεπτά και η εφαρμογή μου εμφάνιζε το εξής error:

```
Creating vector...
Exception in thread "main" java.lang.OutOfMemoryError Create breakpoint : Java heap space
    at java.base/java.text.Format.format(Format.java:159)
    at myLuceneApp.CreateTermDocMatrix.testSparseFreqDoubleArrayConversion(CreateTermDocMatrix.java:181)
    at myLuceneApp.CreateTermDocMatrix.main(CreateTermDocMatrix.java:134)

Process finished with exit code 1
```

Αρχικά έψαξα για λάθη στον κωδικά μου χωρίς να παρατηρήσω κάτι, δεδομένου και οτι το πρόγραμμα λειτουργούσε σωστά για το 1ο ερώτημα. Επιχείρησα να αυξήσω το max heap size αλλάζοντας τα memory settings και αυξάνοντας την μέγιστη διαθέσιμη μνήμη μέχρι και 4GB με τον εξής τρόπο στα settings του IntelliJ -Xmx4096m, αύξησα την ελάχιστη μνήμη που γίνεται allocate με το -Xms2024m, αλλά και πάλι συνέχιζε να εμφανίζεται το ίδιο error.
Με περαιτέρω debugging είδα οτι το πρόβλημα εμφανιζόταν μετα από περίπου 5900 loops του παρακάτω, στην μέθοδο “testSparseFreqDoubleArrayConversion(IndexReader reader)”

```
for (ScoreDoc scoreDoc : indexSearcher.search(new MatchAllDocsQuery(), Integer.MAX_VALUE).scoreDocs) {
    Terms docTerms = reader.getTermVector(scoreDoc.doc, field: "contents");
    while (scoreDoc.doc + c >1992 && scoreDoc.doc + c <1998) {
        for (int i = 0; i < fieldTerms.size(); i++) {
            svdVector[i][scoreDoc.doc + c] = "0";
        }
        c++;
    }
    Double[] vector = DocToDoubleVectorUtils.toSparseLocalFreqDoubleArray(docTerms, fieldTerms); //crea
    for (int i = 0; i < vector.length; i++) {
        svdVector[i][scoreDoc.doc + c] = nf.format(vector[i]);
    }
}
```

Τελικά κατέληξα στο να γυρίσω στην κλάση TXTParsing και να αφαιρέσω από όλα τα texts όλους τους ειδικούς χαρακτήρες επιχειρώντας να μειώσω το μέγεθος των terms και άρα το μέγεθος του πίνακα που δημιουργούσα με την παρακάτω εντολή στο TXTParsing.java:

```
55                text = text.replaceAll( regex: "\\W",  replacement: " ");
56                mydoc = new MyDoc(id,title,text.trim());
57                parsed_docs.add(mydoc);
58            }
59        }
```

Με αυτήν την προσθήκη κατάφερα να ολοκληρώσω την Φαση 3 αλλά με πλεον **13033 terms,** μπορεί να γίνει αναπαραγωγή του error αν αφαιρεθεί η εντολή στην σειρά 55 του αρχείου TXTParsing.java και γίνει run του “CreateTermDocQueMatrix.java”.
PC Specs: CPU-Ryzen 5 3600, RAM-16GB@3200MHz, Storage-500GB NVME SSD

Αναφορά

1.)Αναπαράσταση συλλογή κειμένων σαν πίνακα διαστάσεων termsXdocuments.

Για την αναπαράσταση του πίνακα επεξεργάστηκα τον κώδικα που μας δώθηκε στο εργαστήριο προκειμένου να λειτουργεί με την συλλογή κειμένων LISA.
Από την 1η προγραμματιστική εργασία χρησιμοποιήσα τις κλάσεις “MyDoc” και “TXTParsing” που χρησιμοποιούνται από τον “CreateTermDocMatrix” αρχικά για την παραγωγή του Index και έπειτα για την παραγωγή του πίνακα και την εγγραφή του σε ένα αρχείο “luceneDocVector.csv” με σκοπό να χρησιμοποιηθεί για SVD ανάλυση.

Κατα την δημιουργία του “IndexWriter” πρόσθεσα το εξής configuration έτσι ώστε να κάνει overwrite ήδη υπάρχοντα ευρετήρια εάν αυτά υπάρχουν στον φάκελο index.

```
108            config.setOpenMode(IndexWriterConfig.OpenMode.CREATE);
```

Για την δημιουργία του Index η διαδικασία είναι παρόμοια με την πρώτη φάση καλώντας αυτή την φορά την “addDocWithTermVector();”με μοναδική αλλαγή το εξής πεδίο:

```
//TextField title = new TextField("title", value, Field.Store.YES);
Field field = new Field( name: "contents", fullSearchableText, type);
```

Πλέον δημιουργούμε στο ευρετήριο προσθέτουμε τύπους “Field” αντί για “TextField” επειδή χρειάζεται η παραμετροποίηση που προσφέρεται από το πεδίο “type”.

Αφού δημιουργηθεί το ευρετήριο, δημιουργούμε έναν “IndexReader” για να το διαβάσει και τον χρησιμοποιούμε σαν όρισμα στην μέθοδο “testSparseFreqDoubleArrayConversion(reader)” που θα δημιουργήσει τον πίνακα termsXdocuments.

Η συλλογή μου σε αυτό το σημείο αποτελούνταν από:

Terms: 13161
Documents: 5999
IDs: 6004

Επειδή η αξιολόγηση γίνεται με βάση τα IDs δημιουργώ έναν πίνακα διαστάσεων 13161X6004 και παρατηρώ οτι στο αρχείο “LISA1.501” τα λείπουν τα κείμενα με ID 1993 έως 1997, προσθέτω μερικα «κενά» κείμενα στον πίνακα σε αυτές τις θέσεις με τον εξής τρόπο:

```
while (scoreDoc.doc + c >1992 && scoreDoc.doc + c <1998) {
    for (int i = 0; i < fieldTerms.size(); i++) {
        svdVector[i][scoreDoc.doc + c] = "0";
    }
    c++;
}
```

Με χρήση “DocToDoubleVectorUtils.toSparseLocalFreqDoubleArray(docTerms, fieldTerms);“ δημιουργούμε ένα vector[] που αποθηκεύει πόσες φορές εμφανίζεται το κάθε term μέσα στο document που εξετάζουμε.

Διατρέχουμε τον vector[] και αποθηκεύουμε τα αποτελέσματα του στα κατάλληλα rows του svdVector[][] κρατώντας σταθερή την στήλη, η στήλη αυξάνεται όταν εξετάσουμε το επόμενο Document.

Με χρήση της “writeVector(svdVector)”, αν υπάρχει ήδη αρχείο με το όνομα “luceneDocVector.csv” το κάνουμε overwrite, αν δεν υπάρχει τότε το δημιουργούμε και γράφουμε σε αυτό τον πίνακα termsXdocuments

2.)Παραγοντοποίηση του αραιού πίνακα εφαρμόζωντας SVD ανάλυση

Αναζήτησα βιβλιοθήκες που να μπορούν να εφαρμόσουν SVD ανάλυση στον πίνακα, μια εξ’αυτών ήταν η βιβλιοθήκη “JAMA” χωρίς όμως να παράγει κάποιο αποτέλεσμα ακόμα και αν το «άφησα να τρέχει» για περίπου δύο ώρες. Συνάδελφοι ανέφεραν ότι κατάφεραν SVD ανάλυση με “JAMA” αλλά χρειάστηκε να περιμένουν 7+ ώρες.

Σε αυτό το σημείο αποφάσισα οτι το debugging θα ήταν αδύνατο αν χρειαζόταν να περιμένω κάθε φορά 7 ώρες για την SVD ανάλυση οπότε χρησιμοποίησα Python.

Στον φάκελο “src\\svd\\exercise2” βρίσκεται το άρχειο “luceneDocVector.csv” που δημιουργήθηκε από την “CreateTermDocMatrix” και το python script “svdEx2.py” με το οποίο έκανα SVD ανάλυση.

3.) Αναπαράσταση ερωτημάτων ως διανύσματα

Για τον σκοπό της άσκησης και για να είναι εμφανής η διαφορά μεταξύ του 1ου και του 3ου ερωτήματος δημιούργησα μια καινούρια main με όνομα “CreateTermDocQueMatrix”. Τροποποίησα κατάλληλα την κλάση TXTParsing επειδή τα Queries που μου δώθηκαν είχαν διαφορετική δομή.

Δομή Document

ID: Document 3532
Title: Summary of main text
Mesh: Main text of the document

Δομή Queries

ID: 3532
Title:
Mesh: Main text of the document

Επομένως με την προσθήκη των κατάλληλων if statement στο TXTParsing καταφέρνω μία ομοιόμορφη δομή μεταξύ των δύο για να ενταχθούν οι όροι στο ευρετήριο.

```
IndexWriter writer = new IndexWriter(index, config);

List<List<MyDoc>> docList = new ArrayList();
// parse txt document using TXT parser and index it
for (int i=0; i< 14; i++) {
    docList.add(TXTParsing.parse(docTxtFile.get(i), action: "d"));
}

for(List<MyDoc> list : docList){
    for (MyDoc doc : list){
        addDocWithTermVector(writer, doc, type, action: "d");
    }
}
List<MyDoc> docs =  TXTParsing.parse(queryTxtFile, action: "q");
for (MyDoc doc : docs){
    addDocWithTermVector(writer, doc, type, action: "q");
}

writer.close();
```

Με χρήση της “addDocWithTermVector()” δημιουργούμε το ευρετήριο και κλείνουμε τον writer.

Ανοίγουμε έναν “IndexReader” και διαβάζουμε το ευρετήριο που δημιουργήθηκε, και καλούμε την “testSparseFreqDoubleArrayConversion(reader)” για να αναπαραστήσω την συλλογή κειμένων και τα queries σε έναν ενιαίο πίνακα με ένα ενιαίο ευρετήριο. Το ευρετήριο πλέον έχει μέγεθος 13303 > 13161 που είχαμε στο πρώτο ερώτημα, λογικό καθώς προσθέσαμε και τα terms που έχουν τα queries και δεν εμφανίζονται στα Docs.

Ο αριθμός των συνολικών Documents είναι πλέον 6039, αφού πήραμε τα 6004 Documents της συλλογής και προσθέσαμε τα 35 κείμενα από τα queries

Δημιουργούμε το 2D Array svdVector με μέγεθος terms(13303)XDocumentsQueries(6039), οπου κάθε στήλη αναπιριστά ένα Document ή ένα query και κάθε row αναπαριστά πόσες φορές εμφανίζεται το term στο Document/Query.

Καλούμε την writeVector(svdVector) προκειμένου να δημιουργήσουμε 2 .csv αρχεία

Το ένα ονομάζεται “luceneDocVector.csv” και έχει μέγεθος termsXdocuments δηλαδή 13303X6004.

Το δεύτερο αρχείο ονομάζεται “luceneQueVector.csv” και έχει μέγεθος termsXqueries δηλαδή 13303X35 και τα αποθηκεύουμε στον φάκελο “src\\svd\\exercise4” προκειμένου να χρησιμοποιηθούν με χρήση της python για τον υπολογισμό της συνημιτονοειδής ομοιότητας των διανυσμάτων.

4.)Για τον υπολογισμό της συνημιτονοειδής ομοιότητας των διανυσμάτων των ερωτημάτων με τα διανύσματα των κειμένων χρησιμοποίησα Python όπως και στο ερώτημα 2, στον πίνακα termsXdocuments (διαστάσεων: 13303x6004).

Στον φάκελο “src\\svd\\exercise4” βρίσκεται το άρχειο “luceneDocVector.csv” και “luceveQueVector” που δημιουργήθηκε από την “CreateTermDocQueMatrix”, και το python script “svdEx4.py” με το οποίο έκανα SVD ανάλυση και τον υπολογισμό της συνημιτονοειδής ομοιότητας.

Έχω 35 queries και για κάθε query τρέχω την συνάρτηση cosine_similarity, η οποία με την “txq.iloc[:, q] παίρνει όλα τα terms για το query που δίνεται σαν όρισμα, και υπολογίζω την συνημιτονοειδή ομοιότητα με τον τύπο της.

Κανω sort με το -cosineSimilarity για να ταξινομηθούν τα φθίνουσα σειρά και τα γράφω στο αντίστοιχο αρχείο, στο .py αρχείο που παρέδωσα έχω για RankApproximation k=50 και γράφω αρχεία LISARESULTS για 20, 30 και 50 κείμενα.

5.)Αποτελέσματα στον φάκελο trec_eval\\RankApproximation\\k50
Rank Approximation = 50

Μέτρο Αξιολόγησης / **Κ πρώτα Ανακτηθέντα κείμενα**	MAP (Mean Average Precision)	avgPre@k (Average Precision @k)
K = 20	0.0303	P_05 = 0.0471 P_10 = 0.0441 P_15 = 0.0451 P_20 = 0.0485
K = 30	0.0316	P_05 = 0.0471 P_10 = 0.0324 P_15 = 0.0353 P_20 = 0.0368
K = 50	0.0582	P_05 = 0.0412 P_10 = 0.0382 P_15 = 0.0314 P_20 = 0.0279

Συγκριτικά με την πρώτη φάση, παρατηρούμε κατά πολύ μικρότερο map και Average Precision @k που υποδεικνύει οτι για την συγκεκριμένη συλλογή αυτή η μέθοδος ανάκτησης κειμένων δεν είναι τόσο καλή και ίσως να ταίριαζε καλύτερα το μοντέλο ανάκτησης διανυσματικού χώρου.

Παρόλα αυτά παρατηρούμε «λογικούς» αριθμούς καθώς το map αυξάνεται όσο αυξάνονται τα Κ πρώτα ανακτηθέντα κείμενα.

6)
Αποτελέσματα στον φάκελο trec_eval\\RankApproximation\\k150
Rank Approximation = 150

Μέτρο Αξιολόγησης / **Κ πρώτα Ανακτηθέντα κείμενα**	MAP (Mean Average Precision)	avgPre@k (Average Precision @k)
K = 20	0.0371	P_05 = 0.0647 P_10 = 0.0676 P_15 = 0.0686 P_20 = 0.0676
K = 30	0.0319	P_05 = 0.0588 P_10 = 0.0647 P_15 = 0.0608 P_20 = 0.0647
K = 50	0.0264	P_05 = 0.0294 P_10 = 0.0353 P_15 = 0.0373 P_20 = 0.0397

Αποτελέσματα στον φάκελο trec_eval\\RankApproximation\\k300
Rank Approximation = 300

Μέτρο Αξιολόγησης / **Κ πρώτα Ανακτηθέντα κείμενα**	MAP (Mean Average Precision)	avgPre@k (Average Precision @k)
K = 20	0.0340	P_05 = 0.0706 P_10 = 0.0765 P_15 = 0.0824 P_20 = 0.0691
K = 30	0.0303	P_05 = 0.0529 P_10 = 0.0588 P_15 = 0.0686 P_20 = 0.0721
K = 50	0.0239	P_05 = 0.0294 P_10 = 0.0353 P_15 = 0.0353 P_20 = 0.0338

Για Rank Approximation 150 και 300 παρατηρούμε οτι όσο το Κ αυξάνεται, το MAP μειώνεται σε αντίθεση με τα αποτελέσματα για Rank Approximation = 50 και σε αντίθεση και μετα αποτελέσματα της 1^{ης} φάσης της εργασίας.

Αυτό μπορεί να είναι κάποιο πρόβλημα στον κώδικα κατα τον υπολογισμό της συνημιτονοειδούς ομοιότητας, κάποια ιδιομορφία της συλλογής ή και να φταίει που χρειάστηκε να αφαιρέσω τους ειδικούς χαρακτήρες από τα κείμενα πριν την δημιουργία του Index.